

Plan Maestro de Investigación Secundaria: ¿Fueron las lluvias de 2025 en México atípicas?

Grupo de Investigación Anomalocarís¹

Doctorado en Ciencias e Ingeniería de la Computación (DCIC)
Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas (IIMAS)
Universidad Nacional Autónoma de México (UNAM) · Abril 2026
`dcic@iimas.unam.mx`

Resumen Este documento constituye el plan maestro de la investigación secundaria asignada al Grupo Anomalocarís, cuya línea principal es la detección de transferencias bancarias fraudulentas mediante técnicas adaptativas de aprendizaje automático. La pregunta central que guía esta investigación es: *¿Las precipitaciones de México durante 2025 representan una anomalía estadísticamente significativa respecto al comportamiento histórico regional?* Se propone un diseño metodológico en cuatro fases que integra métodos estadísticos clásicos (índices SPI/SPEI, pruebas no paramétricas, detección de puntos de cambio) con un pipeline de *machine learning* para detección de anomalías no supervisada, clasificación de regímenes pluviométricos, detección de *concept drift* y atribución causal mediante XAI/SHAP. El plan incluye fuentes de datos verificadas con enlaces directos, un cronograma de seis meses, métricas cuantificables y un análisis explícito del puente metodológico entre la detección de fraude y la detección de anomalías climáticas.

Keywords: Detección de anomalías · SPI/SPEI · Concept drift · ML climático · ENSO · XAI · México

1. Definición del Problema

1.1. Contexto y justificación

Esta investigación se enmarca como línea secundaria del Grupo Anomalocarís. Aunque el dominio es climático, la epistemología metodológica es idéntica a la detección de fraude: determinar si el año pluviométrico 2025 constituye una anomalía estadísticamente significativa respecto al comportamiento histórico de referencia. Las competencias en modelos adaptativos, detección de *concept drift* y explicabilidad son directamente transferibles.

1.2. Pregunta de investigación central

PREGUNTA CENTRAL
¿Las precipitaciones registradas en México durante 2025 representan una anomalía estadísticamente significativa respecto al comportamiento histórico regional, considerando variabilidad espacial, temporal y los patrones asociados a fenómenos climáticos de gran escala (ENSO, PDO, AMO, MJO)?

1.3. Subpreguntas derivadas

Tabla 1: Subpreguntas de investigación, naturaleza y método principal.

#	Subpregunta	Naturaleza	Método principal
Q1	¿Qué regiones presentaron desviaciones más pronunciadas?	Espacial	SPI+Kriging+Isolation Forest
Q2	¿En qué períodos del año se concentraron las anomalías?	Temporal	Serie de tiempo + ADWIN
Q3	¿Existe correlación con ENSO, MJO, PDO o AMO?	Mecanística	Regresión + SHAP
Q4	¿Los métodos clásicos y de ML coinciden?	Metodológica	Comparación SPI vs. ML
Q5	¿Se detecta <i>concept drift</i> en 2020–2025?	Teórica	ADWIN, KSWIN, PELT

1.4. Hipótesis de trabajo

H₀ — Hipótesis nula
Las precipitaciones de 2025 en México son estadísticamente compatibles con la variabilidad histórica observada en el período 1981–2024.

H₁ — Hipótesis alterna
Al menos una región climática de México presentó precipitaciones de 2025 cuya distribución difiere significativamente del comportamiento histórico de referencia, tras controlar por teleconexiones climáticas conocidas (ENSO, PDO, AMO, MJO).

1.5. Puente metodológico: fraude bancario ↔ lluvia atípica

Tabla 2: Correspondencia metodológica entre la línea principal (fraude) y esta investigación (anomalías climáticas).

Detección de fraude (línea principal)	Detección de lluvia atípica (esta investigación)
Transacción anómala	Evento pluviométrico extremo
<i>Concept drift</i> temporal	Cambio climático / cambio de régimen
Clase minoritaria (fraude $\approx 0.31\%$)	Eventos raros (percentil >95)
XAI/SHAP (cumplimiento regulatorio)	Atribución de anomalía a forzantes
<i>Walk-forward</i> (sin <i>leakage</i>)	<i>Walk-forward</i> sobre series climáticas
ADWIN/KSWIN sobre transacciones	ADWIN/KSWIN sobre precipitación mensual
VAE-Drift: espacio latente $\mathcal{Z}$	Autoencoder LSTM en series pluviométricas

2. Marco Teórico y Conceptual

2.1. Concepto de «lluvia atípica»

El análisis debe responder tres preguntas antes de aplicar cualquier método:

- **¿Atípica respecto a qué?** → Período de referencia WMO 1981–2010.
- **¿Atípica en qué dimensión?** → Acumulado anual, intensidad, frecuencia de extremos, distribución estacional.
- **¿Medida con qué método?** → Índices SPI/SPEI o modelos de ML.

2.2. Índices estándar

Tabla 3: Índices climatológicos estándar utilizados en el análisis.

Índice	Descripción y uso	Referencia
SPI- k	Anomalía pluviométrica multi-escala ($k=1,3,6,12$ meses). Base del análisis.	McKee et al. [1]
SPEI	SPI más evapotranspiración; sensible al calentamiento global.	Vicente-Serrano et al. [2]
RX1day/RX5day	Precipitación máxima en 1 y 5 días. Extremos de corta duración.	ETCCDI/IPCC AR6 [7]
R95p	Total de precipitación en días sobre el percentil WMO (2009) 95.	
CDD/CWD	Días consecutivos secos/húmedos. Persistencia de anomalías.	IPCC AR6 [7]

2.3. Teleconexiones climáticas relevantes para México

Tabla 4: Índices de teleconexión climática con relevancia para México.

Índice	Relevancia para México	Forzante físico
ONI (ENSO)	Principal forzante interanual. La Niña favorece sequías en el norte.	SST Pacífico tropical (Niño3.4)
PDO	Modulación decadal (20–30 años). Amplifica/atenua ENSO.	SST Pacífico Norte extratropical
AMO	Influencia del Atlántico en el Golfo y sureste (60–80 años).	SST Atlántico Norte 0–70°N
MJO	Variabilidad intraestacional (20–90 días). Modula <i>onset</i> de lluvias.	Perturbación convectiva ecuatorial

2.4. Formulación matemática base del SPI

$$z(i, t) = \frac{P(i, t) - \mu_{\text{ref}}(i)}{\sigma_{\text{ref}}(i)} \quad (1)$$

donde $P(i, t)$ es la precipitación observada, $\mu_{\text{ref}}(i)$ y $\sigma_{\text{ref}}(i)$ son la media y desviación estándar históricas 1981–2010. El SPI- k ajusta una distribución Gamma a acumulados de k meses y la transforma a normal estándar.

3. Diseño Metodológico

3.1. Cuatro fases

Tabla 5: Fases del diseño metodológico.

Fase	Descripción	Duración
F1	Adquisición y calidad: descarga CLICOM/ERA5/CHIRPS v3; test SNHT; relleno por kriging.	Meses 1–2
F2	Análisis estadístico: z -score, SPI- k , SPEI; pruebas no paramétricas; puntos de cambio PELT.	Meses 2–3
F3	Modelado ML: Isolation Forest, LOF, VAE-LSTM; clasificación; <i>concept drift</i> ; SHAP.	Meses 3–4
F4	Síntesis: integración de resultados, atlas de anomalías, redacción de reporte y artículo.	Meses 4–6

3.2. Fuentes de datos — observaciones en tierra

Tabla 6: Fuentes de observaciones meteorológicas con enlace de descarga directo.

Fuente	Org.	Resolución	Portal y descarga
CLICOM (SMN)	SMN-CONAGUA	Diaria 1920–2025 ≈5,400 est.	smn.conagua.gob.mx — Información Estadística
CLICOM malla (CICESE)	CICESE	Diaria + malla 1920–2012	clicom-mex.cicese.mx
Resúmenes Mensuales	SMN-CONAGUA	Mensual por estado	smn.conagua.gob.mx — Resúmenes Mensuales
SIG-ERIC (IMTA)	IMTA	Red referencia	hidrosuperf.imta.mx/sig_eric
SIH-CONAGUA	CONAGUA	Horaria 2022–2025	sih.conagua.gob.mx

3.3. Fuentes de datos — reanálisis y satélite

Tabla 7: Fuentes de reanálisis y estimación por satélite con descarga directa.

Fuente	Res.	Cobertura	Portal y descarga directa
ERA5 (ECMWF/Copernicus)	0.25° h	1940–hoy	ECMWF — ERA5 overview CDS — ERA5 Single Levels (descarga)
CHIRPS v3 (CHC-UCSB)	0.05° d	1981–hoy	chc.ucsb.edu/data/chirps3 (v3 operacional) chirps v2 — descontinuado dic-2026
PERSIANN- CDR	0.25° d	1983–hoy	CHRS Data Portal (interactivo) NOAA NCEI — PERSIANN-CDR
GPM IMERG V07 (NASA)	0.1° 30m	Jun 2000–hoy	gpm.nasa.gov/data/imerg GES DISC — IMERG Final mensual V07

3.4. Índices de teleconexiones climáticas

Tabla 8: Índices de teleconexión: fuente y descarga directa (todos en NOAA PSL).

Índice	Fuente	Portal web	Descarga directa
ONI	NOAA PSL	psl.noaa.gov/data/climate/indices	Descarga ONI mensual
PDO	NOAA PSL	psl.noaa.gov/data/climate/indices	Descarga PDO mensual
AMO	NOAA PSL	psl.noaa.gov/data/climate/indices	Descarga AMO mensual
MJO	NOAA CPC	NOAA CPC — MJO O. Índices MJO diarios	
Todos	NOAA PSL	psl.noaa.gov — portal central	Índices disponibles

3.5. Análisis estadístico clásico

Homogeneización. Test SNHT (Alexandersson) para rupturas de homogeneidad; relleno por kriging ordinario o IDW con validación *leave-one-out*; período de referencia WMO 1981–2010 (comparativo: 1991–2020).

Tabla 9: Pruebas estadísticas aplicadas por región climática.

Prueba	Objetivo	Umbral
Mann-Whitney U	Diferencia de medianas 2025 vs. histórico por $p < 0,05$ (FDR) región	
Kolmogorov-Smirnov	Diferencia en distribución completa	$p < 0,05$
Mann-Kendall	Tendencia monotónica en la serie 1981–2025	$p < 0,05$; S y τ
PELT (<i>ruptures</i>)	Punto de cambio estructural en la serie larga BIC; ventana ≥ 5 años	

Pruebas de hipótesis.

3.6. Pipeline de *machine learning*

Regla de oro: separación temporal estricta

La clase normal se define **únicamente** con datos 1981–2022. El año 2025 se trata como datos de prueba completamente no vistos. **NUNCA** mezclar 2025 en el entrenamiento — equivale al *data leakage* temporal prohibido en la detección de fraude.

Tabla 10: Modelos no supervisados para detección de anomalías climáticas.

Modelo	Mecanismo	Justificación
Isolation Forest [5]	Aislamiento por particionado aleatorio	Baseline estándar; eficiente en alta dimensión
LOF	Densidad local vs. vecinos k -NN	Anomalías contextuales locales por región
One-Class SVM	Frontera en espacio de características (RBF)	Robusto para normalidad de geometría compleja
Autoencoder LSTM	Reconstrucción temporal; error = <i>score</i>	Dependencias de largo plazo en series mensuales
VAE temporal	Distribución en espacio latente $\mathcal{Z}$	Alineado con C2-VAE-Drift de la tesis

Módulo A — Detección de anomalías (no supervisado).

Módulo B — Clasificación supervisada. Etiquetas derivadas del SPI-12: seco extremo (< -2), seco moderado, normal, húmedo moderado, húmedo extremo ($> +2$). Modelos: Random Forest, XGBoost, LightGBM. Validación: *walk-forward* temporal.

Tabla 11: Detectores de *concept drift* aplicados a precipitación mensual.

Detector	Aplicación climática	Implementación
ADWIN [6]	Cambio en media/varianza de acumulados mensuales	<code>river.drift.ADWIN</code>
Page-Hinkley	Cambio abrupto en acumulados anuales	<code>river.drift.PageHinkley</code>
KSWIN	Cambio distribucional sin supuestos paramétricos	<code>river.drift.KSWIN</code>
PELT	Punto de cambio estructural (ventana ≥ 5 años)	<code>ruptures.Pelt</code>

Módulo C — *Concept drift* pluviométrico.

Módulo D — Atribución XAI/SHAP. SHAP TreeExplainer sobre XGBoost (Módulo B) para cuantificar la contribución de cada forzante (ONI, PDO, AMO, MJO, altitud, región) a clasificar el año 2025 como anómalo. Validar coherencia física con climatólogo externo.

4. Regionalización Climática

Tabla 12: Regiones climáticas de México con régimen y forzante dominante.

Región (estados)	Régimen pluviométrico	Forzante dominante
Noroeste (Sonora, Sinaloa, BCS)	Monzón Mexicano (jun.–sep.)	Pacífico Tropical (ENSO), NAM
Norte árido (Chihuahua, Coahuila)	Precipitación escasa y convectiva	ENSO fase fría, frentes invernales
Centro (CDMX, Jalisco, Puebla)	Verano marcado (may.–oct.)	ITCZ, ondas del este, MCC
Golfo (Veracruz, Tabasco)	Alta precipitación; ciclones frecuentes	AMO, vaguadas polares, ciclones
Sureste (Chiapas, Yucatán)	Bimodal o muy húmedo	ITCZ, MJO, ciclones Atlántico
Baja California	Mediterráneo/árido; lluvias invernales	PDO, ENSO fase fría, extratropicales

5. Cronograma de Ejecución

Tabla 13: Diagrama de Gantt simplificado a seis meses. ■ = período activo.

Actividad	M1	M2	M3	M4	M5	M6
Fase 1 — Adquisición y calidad						
Descarga CLICOM / ERA5 / CHIRPS v3	■	■				
Homogeneización (SNHT + kriging)	■	■				
Estadística exploratoria		■				
Fase 2 — Análisis estadístico						
Cálculo SPI- k y SPEI		■	■			
Pruebas hipótesis (MWU, KS)			■			
Puntos de cambio (PELT)			■			
Fase 3 — Modelado ML						
Módulo A: Isolation Forest / LOF / VAE			■	■		
Módulo B: Clasificación regímenes				■		
Módulo C: <i>Concept drift</i>				■	■	
Módulo D: Atribución SHAP					■	
Fase 4 — Síntesis y comunicación						
Atlas de anomalías 2025					■	■
Redacción reporte / artículo					■	■
Revisión y envío						■

6. Métricas de Éxito

Tabla 14: Criterios cuantitativos de éxito del proyecto.

Dimensión	Métrica	Umbral
Anomalía estadística	p -value Mann-Whitney por región	$p < 0,05$ en ≥ 1 región (FDR)
Detección ML	F1-score ponderado (clase extrema)	F1 > 0.75
Consistencia cruzada	Acuerdo SPI-12 $\leftrightarrow$ iForest (κ de Cohen)	$\kappa > 0,60$
<i>Concept drift</i>	ADWIN/KSWIN en ventana 2020–2025	Detección en ≥ 1 región
Atribución XAI	SHAP coherentes con literatura ENSO	Validación con climatólogo
Cobertura geográfica	% estaciones CLICOM procesadas	≥ 70 % de $\approx 5,400$

7. Productos Esperados

1. **Base de datos procesada:** precipitaciones 1981–2025 (CLICOM + ERA5 + CHIRPS v3), regionalizada. Formato NetCDF + CSV.
2. **Atlas de anomalías 2025:** mapas SPI-12, z -score e Isolation Forest a nivel estatal y por región.
3. **Reporte técnico integrado:** diagnóstico estadístico + ML con conclusión formal sobre H_0/H_1 .
4. **Artículo técnico** (Semestre 5): envío a *Atmósfera* (UNAM), *Int. J. Climatology* (Wiley) o *Climate Dynamics* (Springer).
5. **Documento de transferencia metodológica:** puente fraude $\leftrightarrow$ clima para apéndice de la tesis doctoral.
6. **Script Python reproducible:** pipeline de adquisición automatizado (CDS API, CHIRPS v3, NOAA PSL) con README y pruebas unitarias.

8. Herramientas Python

Tabla 15: Librerías Python recomendadas con enlace a documentación oficial.

Librería	Función principal	Documentación
<code>climate-indices</code>	Cálculo SPI, SPEI, PDSI en Python	github: monocongo/climate_indices
<code>River</code>	ADWIN, KSWIN, Page-Hinkley	riverml.xyz
<code>ruptures</code>	Puntos de cambio PELT, BOCPD	ruptures-docs
<code>pymannkendall</code>	Test de Mann-Kendall	github: mmhs013/pyMannKendall
<code>xarray + cf_grib</code>	Lectura ERA5 NetCDF/GRIB2	xarray.pydata.org
<code>SHAP</code>	Explicabilidad Shapley (TreeExplainer)	shap.readthedocs.io
<code>scikit-learn</code>	Isolation Forest, LOF, OCSVM	scikit-learn.org
<code>PyTorch</code>	Autoencoder LSTM, VAE temporal	pytorch.org

9. Reflexión Metodológica y Checklist

9.1. Reflexión del tutor

Ventaja competitiva del Grupo Anomalocaris

Como grupo especializado en IA para detección de anomalías financieras, poseemos una ventaja real: sabemos construir sistemas robustos para datos no estacionarios, con distribuciones desbalanceadas y exigencias de explicabilidad regulatoria. El reto es **traducir correctamente el dominio**, no reinventar la metodología. La pregunta «¿fueron atípicas las lluvias?» es, en esencia, la misma que «¿fue atípica esta transacción?». Cambia el fenómeno; la epistemología de la anomalía es idéntica.

9.2. Checklist de validación pre-Fase 3

- ☐ ¿Se definió el período WMO 1981–2010 antes de acceder a los datos de 2025?
- ☐ ¿Se verificó la homogeneidad con el test SNHT?
- ☐ ¿Los datos de 2025 están separados del entrenamiento de **todos** los modelos ML?
- ☐ ¿Se usó *walk-forward* temporal (no *split* aleatorio)?
- ☐ ¿Los acumulados mensuales de 2025 cubren $\geq 70\%$ de las estaciones CLICOM?
- ☐ ¿Se descargaron y verificaron los índices ENSO/PDO/AMO/MJO para 1981–2025?
- ☐ ¿Los SHAP values son físicamente coherentes con la literatura ENSO para México?
- ☐ ¿Los p -values sobreviven corrección FDR (Benjamini-Hochberg)?

9.3. Riesgos y mitigación

Tabla 16: Riesgos metodológicos y estrategias de mitigación.

Riesgo identificado	Estrategia de mitigación
<i>Data leakage</i> : datos de 2025 en entrenamiento	Separación train/test antes de cualquier preprocesamiento
Inhomogeneidad de estaciones	Test SNHT obligatorio; documentar estaciones excluidas
Inflación tipo I: 6 regiones $\times$ múltiples tests	Corrección FDR (Benjamini-Hochberg) sobre todos los p -values
Sesgo de confirmación en SHAP	Validación con climatólogo externo; registrar divergencias
Sesgo de percepción mediática	Anclar en datos; comparar con años análogos (1998, 2010)

Referencias

1. McKee, T.B., Doesken, N.J., Kleist, J.: The relationship of drought frequency and duration to time scales. In: 8th Conf. Applied Climatology, pp. 179–183. AMS (1993). <https://climate.colostate.edu/pdfs/relationshipofdroughtfrequency.pdf>
2. Vicente-Serrano, S.M., Beguería, S., López-Moreno, J.I.: A multiscalar drought index sensitive to global warming: The SPEI. *J. Climate* **23**(7), 1696–1718 (2010). <https://doi.org/10.1175/2009JCLI2909.1>
3. Chandola, V., Banerjee, A., Kumar, V.: Anomaly detection: A survey. *ACM Comput. Surv.* **41**(3), Art. 15 (2009). <https://doi.org/10.1145/1541880.1541882>
4. Barnston, A.G., Tippett, M.K.: Predictions of Niño3.4 SST in CFSv2 and comparison with CFS v1. *Clim. Dyn.* **41**(5–6), 1517–1520 (2013). <https://doi.org/10.1007/s00382-013-1845-4>
5. Liu, F.T., Ting, K.M., Zhou, Z.H.: Isolation Forest. In: Proc. IEEE ICDM, pp. 413–422. IEEE (2008). <https://doi.org/10.1109/ICDM.2008.17>
6. Bifet, A., Gavaldà, R.: Learning from time-changing data with adaptive windowing (ADWIN). In: Proc. SIAM SDM, pp. 443–448. SIAM (2007). <https://doi.org/10.1137/1.9781611972771.42>
7. IPCC: Chapter 11: Weather and Climate Extreme Events. In: Climate Change 2021: The Physical Science Basis (AR6 WGI), pp. 1513–1766. Cambridge Univ. Press (2021). <https://doi.org/10.1017/9781009157896.013>